

Konvolüsyonel Sinir Ağları ile Radyografi Görüntülerinden Pnömoni Tespiti

Pneumonia Detection from Radiography Images using Convolutional Neural Networks

Muhammed TALO

Bilgisayar Mühendisliği Bölümü
Munzur Üniversitesi, Tunceli, Türkiye
muhammedtalo@gmail.com

Özetçe— Pnömoni beş yaş altı çocuk ölümlerinin önde gelen nedeni olmaya devam etmekte ve her gün çoğunluğunu 2 yaş altı bebeklerin oluşturduğu 2,400 çocuk bu hastalıktan yaşamını yitirmektedir. Bu çalışmada, akciğer radyografi görüntüleri üzerinden pnömoni hastalığının tespiti için otomatik bir tanıma sistemi önerilmektedir. Transfer öğrenme yöntemi ile ResNet-152 konvolüsyonel sinir ağı özelleştirilerek, radyografi görüntülerinden pnömoni hastalığının tespiti gerçekleştirilmiştir. Bu özelleştirilmiş mimari ile radyografi görüntüleri üzerinde herhangi bir ön işleme veya manuel özellik çıkarımı yapılmaksızın pnömoni hastalığının tespitinde, %97.4 oranında bir tanıma başarısı elde edilmiştir. Önerilen model, literatürdeki başarılı çalışmalarla karşılaştırıldığında, pnömoni tespit seviyesinin daha yüksek olduğu belirlenmiştir.

Anahtar Kelimeler — pnömoni tespiti; konvolüsyonel sinir ağları; derin öğrenme; KSA.

Abstract—Pneumonia continues to be the leading cause of child mortality in children under the age of five, and 2,400 children, most of whom are babies under 2 years of age, die from pneumonia. In this study, an automated detection system is proposed for the diagnosis of pneumonia with chest radiography images. With the transfer learning technique, ResNet-152 convolutional neural network was customized to recognize pneumonia from radiography images. With this customized architecture, a recognition success of 97.4% was obtained in the detection of pneumonia disease without any preprocessing of raw data or manual feature extraction on radiography images. This model, which was proposed for the detection of pneumonia, found to be more successful when compared with the other successful studies in the literature.

Keywords — pneumonia detection; convolutional neural networks; deep learning; CNN.

I. GİRİŞ

Pnömoni, halk arasında bilinen ismiyle zatürre, özellikle 5 yaş altı çocuklarda görülen en ölümcül hastalık türüdür. Akciğer iltihaplanması olarak da bilinen pnömoni, çocuk ölüm

oranlarının %16'sını oluşturmaktadır [1]. Pnömoni tespiti için kullanılan en yaygın yöntem, akciğer radyografi görüntüleri ile hastalığın tespit edilmesidir. Radyografi görüntüleri ile hastalığın tespiti uzmanlar için de oldukça zordur [2]. Dünya sağlık örgütü raporlarına göre küresel nüfusun sadece üçte birlik kısmı uzman radyologlara ulaşabilmektedir [3].

Bilgisayar destekli sistemler yardımıyla tıbbi görüntülerin hızlı ve doğru bir şekilde analiz edilmesi birçok durumda hayati önem arz etmektedir. Uzmanlar, günlük hayatlarında yaşayabilecekleri dikkat dağınıklığı ve yorgunluk gibi olumsuz etkenlerle yanlış tanı koyabilirler. Bilgisayarlı sistemler, uzmanlara destek sağlayarak onların daha kritik vakalara odaklanmalarını sağlayabilecek niteliktedir.

Yapay zekâ alanının alt kolu olan derin öğrenme yöntemleri kullanılarak tıbbi verilerden çeşitli hastalıkların tespiti [4], sınıflandırılması [5], lokalizasyonu [6] gibi görevler gerçekleştirilmiş ve yapılan uygulamalarda başarılı sonuçlar elde edilmiştir. Tıbbi verilerin analizinde yaygın bir şekilde kullanılan makine öğrenme yöntemleri, yerini daha güncel derin öğrenme yaklaşımlarına bırakmaktadır. Makine öğrenmesi algoritmaları yaklaşımları ile pnömoni tespitlerinde genellikle manuel özellik çıkarımı yapan yöntemler ön plana çıkmıştır [7]. Derin öğrenme mimarilerinde ise konvolüsyonel sinir ağları kullanılarak radyografi görüntüleri üzerinden otomatik hastalık tespiti ve sınıflandırılması yapılmaktadır [8]. 2017 yılında, Wang ve arkadaşları [9], 32,717 hastadan alınan 112,120 göğüs radyografi veri setini açık kaynak olarak yayınladılar. Bu veri seti üzerinde AlexNet, ResNet-50, GoogLeNet, VggNet-16 ve ResNet-50 transfer öğrenme modellerini kullanarak pnömoni tespiti ve lokalizasyonu gerçekleştirdiler ve pnömoni hastalığının sınıflandırılması için eğri altında kalan alan (AUC) değerini en fazla 0.633 olarak rapor etmişlerdir. 2018 yılında Kermany ve diğ. [10], pnömoni hastalığının tespiti ve sınıflandırılması için çocuklardan elde edilen yeni bir akciğer radyografi veri seti yayınladılar. Bu veri seti üzerinde pnömoni hastalığının tespiti için Inception-v3 modelini kullandılar.

Yazarlar normal ve pnömoni olarak sınıflandırılan görüntülerde %92.8 oranında sınıflandırma başarısı elde etmişlerdir. Aynı yıl pnömoni tespiti için Stanford makine öğrenme grubu, 121 katmanlı konvolüsyonel sinir ağı kullanarak 0.768 eğri altında kalan alan değeri elde etmişlerdir [11]. Bir başka çalışmada Guan ve ark. [12], maske çıkarım algoritmalarını kullanarak pnömoni hastalığının tespitinde 0.776 eğri altında kalan alan değeri bildirmişlerdir. [13]'de pnömoni hastalığının tespiti için VggNet-16 mimarisi kullanılmış ve %96.2 tanıma başarısı raporlanmıştır.


Bu çalışmada, pnömoni hastalığını akciğer radyografi görüntülerinden tespit etmek için transfer öğrenme yöntemi ile özelleştirilmiş konvolüsyonel sinir ağı tabanlı ResNet-152 [14] mimarisi kullanılmıştır. Pnömoni hastalığının tespitinde önerilen mimari ile %97.4 tanıma başarısı elde edilmiştir.

II. MATERYAL VE YÖNTEM

Klasik makine öğrenme yöntemleri, işlenmemiş verilerden manuel olarak özellik çıkarımı yapmakta veya diğer makine öğrenme modellerinin çıkarmış olduğu özellikleri kullanmaktadır. Fakat modern derin öğrenme teknikleri, ham verilerden otomatik özellik çıkarımı yaparak veri temsillerini bir ön işleme aşaması gerektirmeksizin öğrenebilmektedirler. Derin öğrenme modelleri yardımıyla otomatik olarak öğrenilen veri temsilleri ile çözülmesi istenilen problem, tek bir göreve indirgenebilmektedir. Günümüzde sağlık alanında kullanımı gittikçe artan derin öğrenme yöntemleri ile tıbbi veri analizi yapılarak çeşitli hastalıkların teşhisinde uzmanlara kolaylıklar sağlanmaktadır [15].

A. Veri seti

Bu çalışmada, Kermany ve ark. [10] tarafından açık kaynak olarak sunulan akciğer radyografi görüntü veri seti kullanıldı. 5856 görüntüden oluşan radyografi veri setinin 1583 tanesi normal gruba, 4273 tanesi pnömoni hastalarına aittir. Bu görüntüler Çin'deki Guangzhou kadın ve çocuk tıp merkezindeki 1-5 yaş arası çocuklardan elde edilmiştir. Şekil 1'de bu veri setine ait örnek radyografi görüntüleri verilmiştir.



Şekil. 1. (1-5) yaş arası çocuklardan alınan örnek radyografi görüntüleri.

B. Konvolüsyonel sinir ağı

Yapay sinir ağlarının daha derin mimarileri olan konvolüsyonel sinir ağları (KSA), tıbbi görüntü verileri üzerinden doğrudan özellik çıkarımı sağlar. Çıkarılan nitelikli özellikler otomatik bir yapay sinir ağına verilerek hastalığın teşhisi, sınıflandırılması veya lokalizasyonu tespit edilebilir.

Standart bir konvolüsyonel sinir ağı genellikle konvolüsyon, aktivasyon, havuzlama (pooling), seyreltme (dropout), normalizasyon ve tam bağlı (fully-connected) katmanlarından oluşur. Konvolüsyon katmanlarında, önceki katmanlardan gelen aktivasyonlar çeşitli filtreler ile işlenerek her bir filtre için özellik haritası çıkarılır. Konvolüsyon katmanlarından elde edilen özellik haritaları, doğrusal olmayan aktivasyon fonksiyonuna iletilir. Aktivasyon fonksiyonları yardımıyla doğrusal olmayan özellikler ağı kazandırılır. Softmax aktivasyon fonksiyonu, sinir ağının çıkışında kullanılarak kategorik bir olasılık dağılımını sağlar. Sinir ağına doğrusal olmayan özellikleri kazandıran ReLU aktivasyon fonksiyonu, genellikle ara katmanlarda kullanılır ve aşağıdaki şekilde tanımlanır [16].

$$\text{ReLU}(x) = \max(0, x)$$

Aktivasyon işlemi sonrası her bir özellik haritası konvolüsyonel katmanlar arasına serpiştirilen havuz katmanında boyutsal olarak küçültülebilmektedir. Böylece ağıdaki parametre sayısı azaltılarak hesaplama miktarı minimuma indirgenmiş olur. Seyreltme katmanı ile ağıdaki bazı nöronlar etkisiz hale getirilerek modelin eğitim verilerini ezberlemesi önlenmektedir. Bu yöntemle ağın başarısı test verilerinde korunmuş olur. Normalizasyon katmanında ağı eğitimi istikrarlı hale getirmek için nörondaki giriş değerleri temel alınarak standartlaştırma işlemi gerçekleştirilir. Modeldeki nöronların parametre güncellemesi ileri ve geri besleme yöntemleri ile sağlanır.

C. Özelleştirilmiş ResNet-152 mimarisi

Bir modeli sıfırdan eğitmek yerine önceden benzer bir problemin çözümü için kullanılan bir modeli transfer ederek kullanmak, derin öğrenme alanındaki en büyük gelişmelerden birisidir. Derin öğrenme modelleri, eğitim için genellikle büyük veriye ihtiyaç duymaktadır. Tıbbi görüntü analizindeki temel problem, veri sayısının çoğunlukla kısıtlı olmasındandır. Mevcut verilerin uzmanlar tarafından tanısı veya sınıflandırılması masraflı bir iştir. Transfer öğrenme yöntemi bu problemlere çözüm sunmaktadır. Başka bir deyişle, transfer öğrenme yöntemi, az sayıda örneğe sahip veri setlerinin eğitimine olanak sağlamaktadır.


Bu çalışmada, açık kaynak ResNet-152 mimarisini özelleştirerek radyografi görüntülerinden pnömoni hastalığının tespiti gerçekleştirilmiştir. ResNet-152 konvolüsyonel sinir ağı 1000 farklı kategoride sınıflandırma yapacak şekilde ImageNet [17] veri seti üzerinde eğitilmiştir. ResNet-152 mimarisi %95.51 başarı oranı ile ILSVRC-2015 yarışmasında birinciliği kazanmıştır. Mimari altı modelin birleşiminden oluşmaktadır.

Konvolüsyonel sinir ağlarında katman sayısının bir noktaya kadar derinleştirilmesi modelin performansını arttırmaktadır. Fakat derinlik arttıkça parametre güncellemeleri sırasında bilgi kaybı oluşmaktadır. Bilgi kaybını önlemek amacıyla ResNet mimarisi, ara katmanları birbirine bağlayan ekstra bağlantılar eklemektedir. Eklenen ara bağlantılar sayesinde modelin eğitimi sırasında doğabilecek bilgi kaybı önlenerek daha derin mimarilerin inşasına olanak sağlanmıştır.

Bu çalışmada transfer öğrenme yöntemi ile ResNet-152 konvolüsyonel sinir ağının özellik çıkaran konvolüsyonel blokları alınarak tam bağlı katmanlar çıkarılmıştır. Konvolüsyonel bloklar üzerine iki tam bağlı katman eklenmiştir. Tam bağlı katmanları takiben modelin hızlı bir şekilde eğitimi sağlayacak iki farklı normalizasyon katmanı tanımlanmıştır. Ayrıca ağın eğitimi sırasında oluşabilecek ezberlemeyi engellemek için de iki tane seyreltme katmanı eklenmiştir. Eklenen ilk tam bağlı katmanlardan sonra ReLU aktivasyon fonksiyonu kullanılmıştır. Ayrıca radyografi görüntülerinden pnömoni tespiti için softmax fonksiyonu yardımıyla modele ikili çıkış (normal-pnömoni) kazandırılmıştır. Önerilen mimarideki katmanların çıkış boyutları ve parametre sayıları Tablo 1’de verilmiştir. Özelleştirilmiş ResNet-152 olarak isimlendirdiğimiz modelin, şematik temsili Şekil 2’deki gibidir.

TABLO I. ÖNERİLEN MİMARİDEKİ KATMANLARIN PARAMETRE SAYILARI VE ÇIKIŞ BOYUTLARI

Katmanlar	Parametre sayısı	Çıkış boyutu
RESNET-152 TABAN KATMANLARI	58,143,808	[32, 4096]
NORMALİZASYON	8192	[32, 4096]
SEYRELTME	0	[32, 4096]
TAM BAĞLI	2,097,664	[32, 512]
NORMALİZASYON	1024	[32, 512]
SEYRELTME	0	[32, 512]
TAM BAĞLI	1026	[32, 2]



Şekil 2. Özelleştirilmiş ReNet-152 mimarisi.

III. DENEYSEL SONUÇLAR VE TARTIŞMA

Özelleştirilmiş ResNet-152 modelinin eğitimi için 11GB hafızaya sahip NVIDIA GeForce GTX 1080 TI ekran kartı kullanıldı. Deneysel işlemler, üzerinde Ubuntu 16.04 işletim sistemi kurulumlu bir Linux sunucuda gerçekleştirilmiştir. Modelin eğitimi Python programlama dili alt yapılı PyTorch [18] ve Fastai [19] kütüphaneleri kullanıldı.

Eğitim ve test kümelerinin bölümünde, sonuçların diğer çalışmalar ile karşılaştırılabilmesi için veri setini sağlayan orijinal makaledeki [10] protokol takip edilmiştir. Eğitim için ayrılan 5232 görüntünün %20’si doğrulama (validasyon) içindir. Modelin testleri, daha önce hiç görmediği 624 radyografi görüntüsü üzerinde gerçekleştirilmiştir. Tablo 2’de akciğer radyografi veri setinin eğitim ve test kümelerindeki dağılımı normal ve pnömoni sınıfları için sunulmuştur.

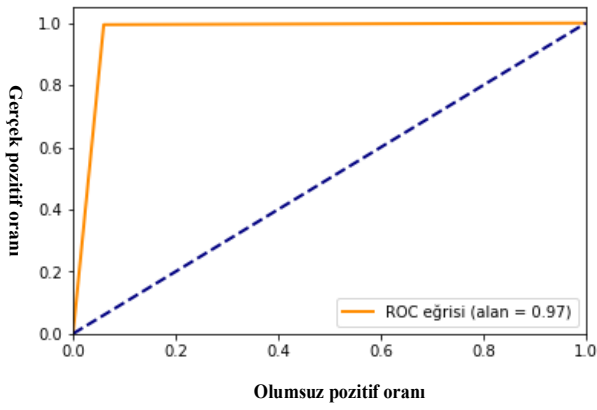
TABLO II. AKCİĞER RADYOGRAFİ VERİ SETİNİN DAĞILIMI

	Normal	Pnömoni	Toplam
Eğitim	1349	3883	5232
Test	234	390	624
Toplam	1583	4273	5856

Ağın parametre güncellemeleri için karekök ortalama hata olasılık (RMSProp) optimizasyon algoritması kullanılmıştır. Ayrıca seyreltme katmanlarında %25 ve %50 oranında nöronlar etkisiz hale getirilmiştir. Transfer öğrenme yöntemi kullanılarak özelleştirilmiş ResNet-152 modelinin eğitimi iki aşamada gerçekleştirilmiştir. Birinci aşamada sadece ResNet-152 taban katmanlarına eklemiş olduğumuz yeni katmanların eğitimi yapılmıştır. Taban katman parametreleri dondurularak bu aşamadaki eğitime dahil edilmemiştir. Birinci aşamada öğrenme oranının $1e-4$ olarak rastgele seçilmesi ile eklenen katmanlar beş devir (epochs) eğitilmiştir.

Eğitimin ikinci aşamasında modelin tüm katmanları (hem ResNet-152 hem de eklenen katmanlar) aktive edilerek modelin eğitime 33 devir daha devam edilmiştir. Eğitim sırasında doğrulama performansının artmadığı gözlemlendiğinde, ağın eğitimi durdurulmuştur. Modelin eğitiminin birinci ve ikinci aşaması sırasıyla yaklaşık 9 ve 62 dakika sürmüştür. Birinci aşamada modelin eğitimi ikinci aşamaya göre daha hızlı olmuştur. Bunun temel nedeni birinci aşamada ResNet-152 transfer modelinin konvolüsyonel katmanlarının dondurulmuş olmasındandır.

Eğitimi tamamlanan modelin testleri, test kümesi üzerinde sağlanmıştır. Şekil 3’te modelin test kümesi üzerindeki ROC grafiği verilmiştir. ROC grafiğinin altında kalan 0.97’lik alan, önerilen modelin test verilerindeki pnömoni ve normal tanı görüntülerinin ayrımının ne kadar iyi yapılabildiğinin göstergesidir. ROC grafiği için; 0.9 - 1 aralığındaki alan değeri mükemmel bir testi temsil ederken; 0.5 - 0.6 aralığı ise başarısız bir testi temsil etmektedir.



Şekil. 3. ROC eğrisi grafiği

Tablo 3'te aynı veri seti [10] üzerinde, pnömoni hastalığının tespiti yapan diğer modeller ile önerilen özelleştirilmiş ResNet-152 modelinin sonuçları karşılaştırılmıştır.

TABLO III. PNÖMONİ TESPİTİ YAPAN ÇALIŞMALARIN KARŞILAŞTIRMALARI

Makale	Yıl	Yöntem	Doğruluk
Kermany ve diğ. [10]	2018	Inception-v3	0.928
Rajaraman ve diğ. [13]	2018	VGG-16	0.962
Önerilen	2019	ResNet-152	0.974

2018 yılında, Kermany ve diğ. [10], pnömoni hastalığının tespiti için açık kaynak olarak yayınladıkları veri seti üzerinde transfer öğrenme yöntemi ile Inception-v3 modelini eğitmişlerdir. Yazarlar, kullandıkları model ile pnömoni hastalığının tespitinde %92.8 oranında tanıma başarısı yakalamışlardır. Aynı yıl, Rajaraman ve arkadaşlarının [13] genelleştirdikleri VGG-16 modeli, aynı veri seti üzerinde %96.2 oranında pnömoni tespit başarısı yakalamıştır. Tablo 3'te görüldüğü gibi bu çalışmada önerilen modelin pnömoni hastalığının tespitindeki performansı, mevcut çalışmalarda kullanılan derin öğrenme modellerine nispeten daha başarılıdır.

IV. SONUÇLAR

Pnömoni hastalığı her yıl yaklaşık iki milyon çocuğun ölümüne neden olmaktadır. Pnömoni hastalığının erken ve doğru tanısı hayati öneme sahiptir. Erken ve doğru tespit tedaviye izin vereceğinden birçok hayatı kurtulabilir. Bu çalışmada, pnömoni hastalığının akciğer radyografı görüntülerinden tespiti için konvolüsyonel sinir ağı tabanlı ResNet-152 modeli özelleştirilmiştir. Pnömoni hastalığının bilgisayar destekli tanı sistemleri ile otomatik tespiti, uzmanlara tanıda kolaylık sağlayacağı gibi uzman erişiminin bulunmadığı bölgelerde ise mevcut personele tanıda yardımcı olabilecek niteliktedir. Pnömoni hastalığı genellikle virüs veya bakteri yolu ile bulaşmaktadır. Virüs ile bulaşan türlerinin tedavisinde yoğun bakım gerekirken, bakteri ile bulaşan türlerde antibiyotik tedavisi önerilmektedir. Sonraki çalışmalarda radyografi görüntüleri üzerinden pnömoni hastalığının türü (viral – bakteriyel) tespit edilebilir. Ayrıca önerilen model farklı pnömoni veri setleri kullanılarak test edilebilir.

KAYNAKLAR

- [1] Pereda, M.A., Chavez, M.A., Hooper-Miele, C.C., Gilman, R.H., Steinhoff, M.C., Ellington, L.E., Gross, M., Price, C., Tielsch, J.M. and Checkley, W., 2015. Lung ultrasound for the diagnosis of pneumonia in children: a meta-analysis. *Pediatrics*, 135(4), pp.714-722.
- [2] World Health Organization, 2001. Standardization of interpretation of chest radiographs for the diagnosis of pneumonia in children.
- [3] Aydogdu, M., Ozyilmaz, E., Aksoy, H., Gursel, G. and Ekim, N., 2010. Mortality prediction in community-acquired pneumonia requiring mechanical ventilation; values of pneumonia and intensive care unit severity scores. *Tuberk Toraks*, 58(1), pp.25-34.
- [4] P. Rajpurkar, J. Irvin, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Ding, A. Bagul, C. Langlotz, K. Shpanskaya et al., "CheXnet: Radiologist-level pneumonia detection on chest x-rays with deep learning," arXiv preprint arXiv:1711.05225, 2017.
- [5] P. Kumar, M. Grewal, and M. M. Srivastava, "Boosted cascaded convnets for multilabel classification of thoracic diseases in chest radiographs," arXiv preprint arXiv:1711.08760, 2017.
- [6] Y. Yuan, M. Chao, and Y.-C. Lo, "Automatic skin lesion segmentation using deep fully convolutional networks with jaccard distance," *IEEE Transactions on Medical Imaging*, 2017.
- [7] Oliveira, L.L.G., e Silva, S.A., Ribeiro, L.H.V., de Oliveira, R.M., Coelho, C.J. and Andrade, A.L.S., 2008. Computer-aided diagnosis in chest radiography for detection of childhood pneumonia. *International journal of medical informatics*, 77(8), pp.555-564.
- [8] Krizhevsky, A., Sutskever, I. and Hinton, G.E., 2012. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems* (pp. 1097-1105).
- [9] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M. and Summers, R.M., 2017, July. Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Computer Vision and Pattern Recognition (CVPR), 2017 IEEE Conference on* (pp. 3462-3471). IEEE.
- [10] Kermany, D.S.; Goldbaum, M.; Cai, W.; Valentim, C.C.S.; Liang, H.; Baxter, S.L.; McKeown, A.; Yang, G.; Wu, X.; Yan, F.; et al. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell* 2018, 172, 1122–1131.
- [11] Rajpurkar, P.; Irvin, J.; Zhu, K.; Yang, B.; Mehta, H.; Duan, T.; Ding, D.; Bagul, A.; Langlotz, C.; Shpanskaya, K.; et al. CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. *arXiv*. 2018.
- [12] Guan, Q.; Huang, Y.; Zhong, Z.; Zheng, Z.; Zheng, L.; Yang, Y. Diagnose like a Radiologist: Attention Guided Convolutional Neural Network for Thorax Disease Classification. *arXiv*. 2018.
- [13] Rajaraman, S., Candemir, S., Kim, I., Thoma, G. and Antani, S., 2018. Visualization and interpretation of convolutional neural network predictions in detecting pneumonia in pediatric chest radiographs. *Applied Sciences*, 8(10), p.1715.
- [14] He, K., Zhang, X., Ren, S. and Sun, J., 2016. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [15] Lundervold, A.S. and Lundervold, A., 2018. An overview of deep learning in medical imaging focusing on MRI. *Zeitschrift für Medizinische Physik*.
- [16] M. Leshno, V. Y. Lin, A. Pinkus, S. Schocken, Multilayer feedforward networks with a nonpolynomial activation function can approximate any function, *Neural networks* 6 (1993) 861–867.
- [17] Deng, J., Dong, W., Socher, R., Li, L.J., Li, K. and Fei-Fei, L., 2009, June. Imagenet: A large-scale hierarchical image database. In *Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE Conference on* (pp. 248-255).
- [18] Ketkar, Nikhil. "Introduction to pytorch." *Deep Learning with Python*. Apress, Berkeley, CA, 2017. 195-208.
- [19] Howard, J.a.o., fastai. *GitHub*, 2018